

NewsAnalyzer: 基於事實查核大盤普查與 多維度 Metadata 融合的即時假新聞防護體系

Real-Time Fake News Detection via Macro Fact-Checking Census & Multi-Signal Metadata Fusion

2,292 筆真實查核大盤

1.48 ms 極速檢索通道

100% 本地端隱私保障

95.3% 實證查核準確率

報告人：林倉裕 (Tsangyu Lin)¹ · 指導教授：惠霖 (Hui Lin)^{1*} · 共同作者：陳聖智 (Sheng-Chih Chen)²

¹ 淡江大學 資訊工程學系所 Intelligent Computing Lab | ² 國立政治大學 National Chengchi University

研究核心總覽：從「語言模型暴力盲猜」到「大盤實證普查」

95.3%

事實查核準確率 (Accuracy)

5 折交叉驗證 F1 達 0.974，遠勝純 LLM (78.4%)

1.48 ms

事實查核快速通道延遲

SBERT 向量檢索，達成點擊即時無感回傳

0 Byte

使用者瀏覽資料外洩量

全端點本地運算，兼顧隱私與 GDPR 規範

傳統純 LLM 暴力判斷的致命盲區

- ▶ 【時效盲區】模型權重凍結，對昨日剛爆發的在地新謠言一無所知
- ▶ 【文風受騙】生成式 AI 偽裝權威語調，純 LLM 極易因語氣客觀而誤判
- ▶ 【缺乏證據鏈】無法提供可溯源的查核機構依據，甚至產生幻覺引用
- ▶ 【延遲與隱私】每次查核需 5~10 秒，且將私密瀏覽軌跡上傳雲端

NewsAnalyzer 多訊號大盤普查解法

- ▶ 【事實查核普查大盤】整合 Cofacts 2,292 筆 IFCN 認證真實查核庫
- ▶ 【多維 Metadata 矩陣】網域黑名單、情緒激化指標、時效衰減懲罰
- ▶ 【非對稱安全錨定】已知謠言強制評分上限 ($S \leq 25$)，杜絕模型翻案
- ▶ 【本地輔助觀點萃取】Gemma-4-12B 專司觀點提煉，100% 隱私

研究背景：繁體中文社交圈的資訊傳播特性與假新聞生態

封閉與半封閉資訊流

- ▶ 高黏著度社群載體：LINE 長輩群組、Facebook 動態牆、Threads 演算法推播
- ▶ 視覺排版同質化：正派新聞報導、未證實健康謠言與內容農場外觀難以肉眼區分
- ▶ 病毒式擴散極速：單一假訊息數小時內轉傳破萬次，傳統人工闢謠嚴重滯後

⚠ 假訊息型態特徵

- ▶ 偽科學健康養生：假借權威名義、誇大療效，針對特定中老年族群精準投放
- ▶ 時事政治深偽：擷取部分真實事實穿插扭曲評論，製造社會恐慌與對立
- ▶ 內容農場誘餌：誇張標題黨搭配未加密 HTTP 網域，賺取廣告流量收益

在地化語言壁壘

- ▶ 台灣在地口語與 slang：諧音梗、在地成語、特定生活與政治詞彙
- ▶ 歐美模型水土不服：直接使用西方 English-centric 模型導致語意嚴重偏移
- ▶ 繁簡跨域無法通用：中國簡體語料事實庫無法涵蓋台灣在地民生議題

痛點解構：為什麼「純 LLM 暴力判斷」在事實查核中必定崩潰？

1. 時效性盲區 (Temporal Blindness)

LLM 的參數權重存在固定的訓練知識截止期 (Knowledge Cutoff)。社群上的假訊息往往是「今天早上」剛編造出的即時謠言，未聯網或純提示詞驅動的 LLM 只能靠舊知識瞎猜，完全無法辨別最新關謠事件。

2. 文風欺騙性 (Stylistic Deception)

現代生成式 AI 能輕易模仿「權威新聞通訊社」的客觀語調。LLM 本質是機率語言模型，當謠言文字結構嚴謹、語氣理性時，純 LLM 會因為其「流暢度與合乎語法」而給出高可信度評分，產生嚴重假陰性。

3. 缺乏證據鏈 (No Auditable Provenance)

純 LLM 給出判決時，無法提供國際事實查核網絡 (IFCN) 認證的真實調查檔案連結。當使用者追問依據時，模型甚至會捏造不存在的專家發言與法規條文（幻覺），嚴重破壞查核工具的公信力。

4. 延遲懲罰與隱私外洩 (Latency & Privacy)

將使用者的即時動態瀏覽內容發送到雲端商業 API（如 GPT-4o），單次請求需 5~10 秒，徹底中斷使用者的瀏覽體驗；同時，將使用者的私密社群 Feed 暴露給第三方伺服器，構成嚴重的隱私外洩風險。

現有事實查核技術範式評估：為什麼既有方法均無法勝任？

① 多數類別基準

Majority Prior

基準準確率 : 88.4%

- ▶ 查核資料庫天然不平衡 (2,025 假 / 267 真)
- ▶ 無腦猜假即可得 88.4% 準確率
- ▶ 致命缺陷：毫無鑑別力，將真新聞全數誤殺

② 傳統特徵分類

Surface NLP (TF-IDF)

基準準確率 : 86.2%

- ▶ 基於詞頻、情緒字典與機器學習分類器
- ▶ 依賴表面字詞特徵 (N-gram)
- ▶ 致命缺陷：極易被同義詞替換與結構改寫破壞

③ 純網域信譽標記

NewsGuard Heuristics

基準準確率 : 52.1%

- ▶ 針對網站 Hostname 評定白名單 / 黑名單
- ▶ 僅適用於獨立內容農場網站
- ▶ 致命缺陷：在 FB/LINE 等同網域社群完全失效

④ 純 Zero-Shot LLM

Prompt-Only LLM

基準準確率 : 78.4%

- ▶ 直接詢問大語言模型「這篇文章是真的嗎」
- ▶ 單純依賴預訓練內化參數
- ▶ 致命缺陷：幻覺頻繁、缺乏在地查核依據

範式評估總結：社群動態內容需要「事實查核大盤」與「Metadata 融合」的複合新體系

既有靜態網域與表面特徵模型無法處理複雜社交語境，而純 LLM 又受限於時效截止與幻覺；必須結合「大盤實證普查 (Cofacts)」與「多維非文本特徵」，才能達成 95.3% 高準確率與 1.48 ms 即時防禦。

核心設計哲學：以實證普查為地基，兼顧端點隱私與極致效能

1. 實證優先

Evidence-First

- ▶ 拒絕無依據的生成式臆測
- ▶ 將已知事實查核數據庫視為最高法庭
- ▶ 命中查核庫時，直接引用 IFCN 認證報告作為權威證據

2. 多維 Metadata

Multi-Signal Fusion

- ▶ 跳脫純文本內容的單一維度
- ▶ 綜合網域黑名單、情緒激化指數、時效衰減因子
- ▶ 多重特徵交叉驗證，補足未收錄文章的判斷力

3. 非對稱安全錨定

Safety Clamping

- ▶ 防範 LLM 被流暢假新聞欺騙
- ▶ 當比對為已知謠言時，強制鎖定評分上限 ($S \leq 25$)
- ▶ 確保模型絕不可能為已證實的假訊息翻案

4. 零外洩端點隱私

Zero Data Egress

- ▶ 100% 本地化運算架構
- ▶ SBERT CPU 向量檢索 (1.48 ms) + 本地 Gemma 顯卡加速
- ▶ 瀏覽記錄與社群貼文絕不離開本機

系統整體架構：三層協同架構 (Client · Gateway · Dual Cores)

Tier 1: Client Tier — Chrome Extension (Manifest V3)

- ▶ DOM MutationObserver：輕量化監聽社群動態牆更新 (Facebook / LINE Web)，滾動載入時自動攔截文章容器
- ▶ 懸浮可互動徽章 UI：在貼文旁即時注入可信度指示燈 (紅 / 黃 / 綠)；點擊即時展開闢謠依據與觀點分析
- ▶ 嚴格本地傳輸：所有請求均透過 localhost:5000 傳輸，無任何第三方外部流量

Tier 2: Gateway Tier — Flask Multi-Signal Fusion Engine (POST /judge)

- ▶ 多維 Metadata 評分矩陣：網域黑名單懲罰、情緒激化指標計算、時效性衰減加權
- ▶ 動態權重融合調度：依據查核庫命中狀態動態調整實證與模型權重 ($w_{\text{fusion}} = 0.10$ vs 0.60)
- ▶ 非對稱安全錨定鉗位：嚴格限制已知謠言評分上限 ($S \leq 25$)，徹底杜絕 LLM 誤判翻案

Tier 3A: 事實查核普查檢索 (CPU)

- ▶ SBERT MiniLM-L12 (384 維稠密向量)
- ▶ Cofacts 2,292 筆真實查核庫
- ▶ 1.48 ms 極速檢索，零顯存佔用

Tier 3B: 本地輔助觀點萃取 (GPU)

- ▶ Gemma-4-12B (Q4_K_M 量化)
- ▶ format:json 文法約束，100% 解析成功率
- ▶ 專司觀點提煉與未命中時的輔助分析

核心模組一：事實查核大盤普查建構與在地化資料庫整合

2,292 筆

有效事實查核紀錄總量

經過字元長度過濾 (>40 字元) 之高品質庫

IFCN 認證

國際事實查核網絡標準

台灣事實查核中心 (TFC) 與 MyGoPen 交叉驗證

99.9%

真實查詢 Top-1 資料庫召回率

對應原句在無擾動下近乎完美精準定位

標籤類別 (Ground Truth Label)	紀錄筆數 (Count)	佔比 (Percentage)	社群語料特徵說明與代表案例
不實假訊息 (inaccurate / false)	1,817 筆	79.3%	誇大養生偏方、政治深偽剪輯、偽造公文詐騙文章
部分不實 / 爭議 (partial)	208 筆	9.1%	真實新聞穿插斷章取義之個人評論、時空背景錯置
真實新聞報導 (accurate / real)	267 筆	11.6%	經查核機構背書之正規調查報導與官方澄清公告
總計有效查核語料庫 (Total)	2,292 筆	100.0%	涵蓋 2020-2026 年台灣 LINE/FB 高傳播度社群闢謠資料

毫秒級 SBERT 語意檢索：CPU-Resident 架構與動態閾值決策

向量空間建模與運算

- ▶ 模型架構：多語言 Sentence-BERT (MiniLM-L12)，輸出 384 維稠密語意向量 ($q \in \mathbb{R}^{384}$)。
- ▶ CPU-Resident 獨立部署：向量編碼與相似度計算全數於 Host CPU 執行，與 GPU LLM 運算完全解耦，零顯存競爭。
- ▶ 靜態矩陣映射：預先將 2,292 筆查核向量編譯為壓縮矩陣 (sbert_index.npz, 2292×384)，開機 instant 記憶體映射載入。

Cosine 語意相似度計算公式

$$\text{sim}(\mathbf{q}, \mathbf{d}_i) = \frac{\mathbf{q} \cdot \mathbf{d}_i}{\|\mathbf{q}\| \|\mathbf{d}_i\|}$$

決策閾值與快速通道機制

- ▶ 雙層過濾策略：
 - 粗篩 (Pre-filter): 0.50 快速取出 Top-5 候選人
 - 精選 (Decision Threshold): $\theta_{\text{sim}} = 0.72$
- ▶ 黃金平衡點 $\theta_{\text{sim}} = 0.72$ ：
 - 覆蓋率 (Coverage): 55.2% 查詢可直接由查核庫秒級裁定
 - 查核準確率 (Accuracy): 達到 95.3%，F1-Score 達 0.974
- ▶ $< 1.48 \text{ ms}$ 極速通道 (Fast-Path)：
當 $\text{sim} \geq 0.72$ 時，直接命中事實依據並回傳，不需調用耗時的 LLM 生成，達成無感即時響應！
- ▶ 抗同義改寫韌性：在 40% 同義詞替換下仍維持 95.4% 準確率。

核心模組二：多維度 Metadata 評分矩陣與非文本特徵提取

1. 網域信譽與黑名單 (M_dom)

- ▶ 內建在地化內容農場黑名單 (Content Farm Blacklist)
- ▶ 權威新聞機構白名單加分機制
- ▶ 未加密 HTTP 協定與可疑子網域扣分懲罰

2. 情緒激化與標題黨指標 (M_sent)

- ▶ 蒸餾情緒分類模型 (DistilBERT) 即時量測文章情緒極性
- ▶ 偵測「震驚、必看、趕快轉發、醫師隱瞞」等煽動性字眼
- ▶ 評估標題與內文的情感張力，抑制誘導點擊之假新聞

3. 時效性衰減懲罰 (M_time)

- ▶ 針對社群上常見「多年前舊謠言重新包裝轉傳」之現象
- ▶ 引入時間指數衰減模型 (Exponential Temporal Decay)
- ▶ 舊有未證實或缺乏近期佐證之時效性事件自動加重扣分

4. 群眾協作回報訊號 (M_crowd)

- ▶ 整合社群回報頻率與爭議度指標
- ▶ 多位查核員對同一主題之共識度 (Consensus Ratio)
- ▶ 計算基礎規則分數 $S_{base} \in [0, 100]$ ，提供堅實的多特徵地基

動態權重融合機制：實證導向與動態自適應加權

動態融合數學模型 (Mathematical Formulation)

$$S_{\text{fused}} = (1 - w_{\text{fusion}}) \cdot S_{\text{base}} + w_{\text{fusion}} \cdot S_{\text{LLM}}$$

自適應權重分派函數 (Adaptive Weight Function)

$$w_{\text{fusion}} = \begin{cases} 0.10, & \text{if } \text{fc_hit} = \text{true} \\ 0.60, & \text{if } \text{fc_hit} = \text{false} \end{cases}$$

- S_{base} 整合網域黑名單、情緒激化與時效衰減
- 查核庫有實證時以實證為主導 (90%)，杜絕純模型誤判！

情境 A: 查核大盤命中 ($\text{fc_hit} = \text{True}$)

- 動態權重設定： $w_{\text{fusion}} = 0.10$ (LLM 僅佔 10%)
- 核心邏輯：既然已存在 IFCN 權威事實查核報告，系統以「真實實證」為主導 (佔比 90%)
- 優勢：避免模型自由發揮而產生反向誤判，確保權威證據鏈絕對優先

情境 B: 查核庫未收錄 ($\text{fc_hit} = \text{False}$)

- 動態權重設定： $w_{\text{fusion}} = 0.60$ (LLM 提昇至 60%)
- 核心邏輯：面對全新未收錄的新聞，調用本地 Gemma-4 進行深度語意邏輯分析
- 安全底線：仍保留 40% Metadata (網域黑名單、情緒) 作為規則防線，防止純模型被騙

非對稱安全錨定：強制分數鉗位，杜絕模型假陰性漏報

非對稱安全錨定數學模型

生成式 AI 假新聞往往文風工整。為防範純 LLM 給出高分誤判，系統建立非對稱安全錨位：一旦檢索判定為已知謠言，立即強制啟動評分上限鉗位 (Score Clamping)！

$$S_{\text{final}} = \begin{cases} \min(S_{\text{fused}}, 25.0), & \text{status} \in \{\text{inaccurate}, \text{false}\}, \text{sim} \geq 0.85 \\ \min(S_{\text{fused}}, 50.0), & \text{status} \in \{\text{inaccurate}, \text{false}\}, 0.72 \leq \text{sim} < 0.85 \\ \min(S_{\text{fused}}, 55.0), & \text{status} = \text{partial} \\ S_{\text{fused}}, & \text{otherwise} \end{cases}$$

► 核心保證：若為已證實之假訊息，評分上限強制鎖定於 $S \leq 25$ ，模型絕不可能翻案！

Tier 1: 高信心確定造假

條件： $\text{sim} \geq 0.85$ 且 inaccurate | 處分： $S_{\text{final}} = \min(S_{\text{fused}}, 25.0)$

強制鎖定為【嚴重可疑造假】，分數上限 25 分，絕不妥協。

Tier 2: 中高信心謠言比對

條件： $0.72 \leq \text{sim} < 0.85$ 且 inaccurate | 處分： $S_{\text{final}} = \min(S_{\text{fused}}, 50.0)$

鎖定為【存疑警告】，分數上限 50 分，強制標記風險。

Tier 3: 部分不實或爭議

條件： $\text{status} \in \{\text{partial}\}$ | 處分： $S_{\text{final}} = \min(S_{\text{fused}}, 55.0)$

鎖定為【部分真實 / 爭議】，分數上限 55 分，提醒讀者注意細節。

本地輔助 LLM 部署：嚴格 JSON 文法約束與觀點提煉

模型定位與文法約束解碼

- ▶ 模型架構：Gemma-4-12B (Q4_K_M 4-bit 量化)，專職「觀點萃取與正反論述整理」，不做孤立裁判。
- ▶ 痛點修復：早期自由文本生成有 15~20% 機率夾帶 Markdown、思考標籤 (<thought>) 或客套對話，導致 JSON 解析失敗。
- ▶ 文法約束 (Grammar-Constrained Decoding)：設定 format:json 與 think:false，在 Token 解碼層直接遮罩非法語法，達成 100% (100/100) 完美解析率！
- ▶ 穩定資源：顯存佔用穩定於 9.2 GB VRAM，單卡 RTX 2080 Ti 即可順暢運作。

嚴格 JSON 結構化輸出綱要 (Schema)

強制輸出四大標準鍵值 (Key-Value)，供前端 UI 即時渲染：

- key_points (Array<string>): 文章核心宣稱與爭議點列表
- viewpoints (string): 第三方權威正反平衡立場 (≤80 字)
- credibility_score (integer): 語意邏輯可信度評分 (0-100)
- analysis (string): 簡要事實查核判定摘要 (≤100 字)

客戶端擴充套件實現： Chrome Manifest V3 與無感互動體驗

Chrome MV3 架構

- ▶ 遵循最新 Google Chrome Manifest V3 規範
- ▶ Service Worker 背景調度，資源開銷極低
- ▶ 支援 Facebook News Feed、LINE Web、X (Twitter)、新聞網站等多平台 DOM 自動解析
- ▶ 本地 Loopback (127.0.0.1:5000) 通訊，無跨域網路風險

MutationObserver 監聽

- ▶ 針對無限滾動 (Infinite Scroll) 社群資訊流最佳化
- ▶ 當貼文節點進入 Viewport 視野時自動捕捉標題、內文與發布來源
- ▶ 非同步背景批次分發，不卡頓使用者日常滑動體驗
- ▶ 自動過濾廣告與無關 UI 節點，精準鎖定文章主體

懸浮可互動徽章 UI

- ▶ 在貼文右上角注入輕量評分徽章：
 - 紅色：高度疑似假新聞 (0-39 分)
 - 黃色：存疑 / 部分不實 (40-69 分)
 - 綠色：權威可信來源 (70-100 分)
- ▶ 點擊即時彈出事實查核詳情面板
- ▶ 顯示 IFCN 原始查證報告連結、核心摘要與正反多方觀點對照

實驗評估一：多層延遲量測與消費級硬體實測效能

1.48 ms

SBERT 查核檢索延遲
CPU 記憶體映射檢索，近乎零延遲

46.7 tok/s

Gemma-4-12B 生成速度
首字延遲 TTFT 僅 200 ms，極速輸出

9.2 GB

GPU 顯存峰值配置
RTX 2080 Ti 單卡即可順暢運行

運算層級 / 評估指標 (Operational Tier)	實測數據 (Empirical Measurement)	架構特性與工程設計說明
SBERT 事實查核普查檢索 (Fast-Path)	1.48 ms (中位數 < 2 ms)	CPU-Resident 常駐記憶體，命中即秒回，零 GPU 競爭
本地 LLM 首字延遲 (TTFT Proxy)	200 ms	Ollama 本地守護進程預載權重，即時啟動 Token 生成
本地 LLM 生成吞吐量 (Throughput)	46.7 tok/s	4-bit Q4_K_M 量化加速，單次觀點分析 (~150 tok) 僅需 3.2 秒
JSON 文法解析遵循率 (Schema Compliance)	100% (100 / 100 次)	format:json 文法約束遮罩，徹底消除語法崩潰與標籤污染
端到端 /judge 完整響應 (Single-Pass)	3.5 秒 (含 DOM 與審計)	單卡 RTX 2080 Ti 顯存穩定留駐 9.2 GB，無系統交換記憶體

實驗評估二：全庫 5 折交叉驗證與多級文字擾動抗壓測試

門檻 θ_{sim}	Verbatim (原句無擾動)	Mild (輕度前綴擾動)	Medium (中度同義改寫)	Heavy (重度結構打亂)
$\theta = 0.55$	Cov: 95% Acc: 91% F1: 0.95	Cov: 95% Acc: 89% F1: 0.94	Cov: 95% Acc: 90% F1: 0.94	Cov: 92% Acc: 89% F1: 0.94
$\theta = 0.65$	Cov: 75% Acc: 94% F1: 0.96	Cov: 75% Acc: 92% F1: 0.96	Cov: 73% Acc: 93% F1: 0.96	Cov: 63% Acc: 92% F1: 0.96
★ $\theta = 0.72$ ★	Cov: 55.2% Acc: 95.3% F1: 0.974	Cov: 54.0% Acc: 95.0% F1: 0.970	Cov: 50.0% Acc: 95.4% F1: 0.975	Cov: 39.0% Acc: 94.4% F1: 0.970
$\theta = 0.85$	Cov: 27% Acc: 97% F1: 0.98	Cov: 24% Acc: 96% F1: 0.98	Cov: 20% Acc: 96% F1: 0.98	Cov: 8% Acc: 97% F1: 0.99

交叉驗證核心發現與抗壓韌性分析

- ▶ 【黃金平衡點 $\theta_{sim} = 0.72$ 】：覆蓋率達 55.2%，準確率高達 95.3% (F1 = 0.974)，達成覆蓋率與精確度的最佳權衡。
- ▶ 【強韌抗擾動能力】：在中度同義詞隨機替換與改寫下，準確率依然逆勢維持 95.4% (F1 = 0.975)，證實 SBERT 語意空間具備極佳泛化性。
- ▶ 【嚴格無洩漏測試】：每一折測試集嚴格排除於候選庫外，無「自己查自己」之數據洩漏，Top-1 真實召回率高達 99.9%。

實驗評估三：四大技術範式橫向綜合基準對比

評估維度 / 特徵指標	多數類別基準	傳統特徵 (TF-IDF)	純網域 (NewsGuard)	純 Zero-Shot LLM	NewsAnalyzer (提議)
查核準確率 (Accuracy)	88.4% (虛高)	86.2%	52.1%	78.4%	★ 95.3% ★
綜合 F1-Score 指標	0.938	0.912	0.634	0.852	★ 0.974 ★
社群 Feed 動態貼文支援	否	部分支援	徹底失效 (同網域)	是	完美支援 (DOM 級)
時效性與動態更新	靜態資料	靜態模型	靜態清單	知識截止盲區	動態普查大盤庫
抗文風偽裝欺騙能力	無	低 (易被改寫)	無	易被客觀語氣騙	高 (實證錨定)
可追溯查核依據 (Audit)	無	無	僅 Hostname	存在幻覺風險	IFCN/Cofacts 連結
推論響應延遲 (Latency)	< 1 ms	5 ms	< 1 ms	3.5 ~ 8.0 秒	1.48 ms (快速通道)
資料外洩與隱私 (Privacy)	零外洩	零外洩	僅查詢網域	雲端 API 高風險	零外洩 (本地端)

實測案例演示：真實內容農場文章端到端攻防驗證

實測農場 URL 攻防流程

- ▶ 測試案例：真實健康詐騙農場文章
(<https://www.pco.tw/news/html/?276.html>)，宣稱特定草藥可治癒慢性病。
- ▶ 步驟一 (DOM 攔截)：擴充套件自動抓取文章標題與 1,200 字內文，送往 POST /judge。
- ▶ 步驟二 (SBERT 檢索)：查核庫無完全對應之歷史紀錄 ($\text{sim} < 0.72$)，回傳 not_found。
- ▶ 步驟三 (Metadata 引擎啟動)：
 - pco.tw 命中在地內容農場黑名單
 - 偵測到誇大養生用詞與極端情緒張力
 - HTTP 基礎規則分數大幅扣分 ($S_{\text{base}} = 12.5$)

最終判定與觀點萃取結果

- ▶ 步驟四 (本地 Gemma 輔助萃取)：
 - 成功萃取核心爭議點 (誇大療效)
 - 提供正規醫學反向觀點 (viewpoints ≤ 80 字)
- ▶ 步驟五 (動態融合計算)：
 - 查核未收錄，指派 $w_{\text{fusion}} = 0.60$
 - 融合評分： $S_{\text{fused}} = 0.40 * (12.5) + 0.60 * (18.0) = 15.8$ 分
- ▶ 最終裁定結果：【高度疑似造假】(Score: 15.9 / 100)
 - 前端徽章即時亮起紅燈警告
 - 成功示範在「未收錄」情況下，多訊號 Metadata 依然具備精準防禦能力！

研究局限與討論：繁簡跨域語意轉移挑戰與種子庫邊界

繁簡跨語系實測落差 (Transfer Gap)

- ▶ 跨域基準測試：將本系統以台灣 Cofacts 訓練之 SBERT 索引，直接評估中國簡體中文 WSDM 2019 假新聞數據集。
- ▶ 實測結果：檢索準確率從 100% 劇降至 55.3%。
- ▶ 核心原因解構：
 1. 詞彙與在地命名差異（例：台灣「健保 / 食藥署 / 外送員」 vs 大陸「醫保 / 市監局 / 外賣小哥」）
 2. 政治與社會時事背景完全不同
 3. 句式文法與流行 slang 存在明顯語義空間偏移 (Domain Shift)

學術啟示與系統建構原則

- ▶ 「一體適用 (One-size-fits-all)」的假新聞模型並不存在：假新聞本質上高度依賴「在地社會脈絡與文化語境」。
- ▶ 在地化種子庫 (Localized Seed Corpus) 的必要性：事實查核系統必須與目標區域的公民查核組織深度綁定，定期同步在地事實資料庫。
- ▶ 啟動延遲最佳化 (Cold-Start Optimization)：早期 SBERT 載入需 108 秒，透過靜態記憶體映射 (mmap) 技術將常駐啟動時間降至秒級。

結論：以實證普查與多訊號融合重塑事實查核防線

NewsAnalyzer 證實了「大盤普查 + Metadata 融合」是解決社群假新聞最具可靠性與隱私保障的架構路徑。在 2,292 筆真實查核樣本下達成 95.3% 準確率與 1.48 ms 極速響應，徹底打破純 LLM 暴力判斷的幻覺瓶頸。

1. 多模態跨媒介偵測

擴展至修圖長輩圖、DeepFake 短影音與社群資訊卡截圖的 OCR 與多模態比對。

2. 跨機構聯合 API 普查

聯合 TFC、MyGoPen、Cofacts 建立自動化增量同步管道，維持實時大盤更新。

3. 開源推廣與生態適配

支援 Firefox / Safari 多瀏覽器生態，並開放社群 API 供在地公民科技使用。

完整開源專案與測試資料集：<https://github.com/min20120907/NewsAnalyzer>

感謝各位評審與先進聆聽 · 敬請指教 (Q&A)